

Universidad Nacional de Colombia

Modelos Lineales Generalizados - 2025 II

.....

Daniel Mauricio Vanegas Oliveros,	dvanegaso@unal.edu.co
Daniela Roncancio Gomez,	droncanciog@unal.edu.co
Jorge Andrés Sanchez Duarte,	josanchezdu@unal.edu.co
Laura Katherine Martinez Castiblanco,	laumartinezca@unal.edu.co

Modelando el Crecimiento del Arbolado Urbano en Bogotá con un Modelo Lineal Generalizado

Descripción

En este trabajo se busca identificar los factores que influyen en el crecimiento del arbolado urbano en Bogotá, empleando para ello un modelo lineal generalizado. La base de datos utilizada corresponde al censo del arbolado urbano de Bogotá D.C., que cuenta con un total de 42,433 registros y 65 variables. Para el análisis, se tomó una muestra de 500 observaciones, seleccionadas mediante muestreo aleatorio simple.

Antes de realizar el análisis, la base de datos fue filtrada para garantizar la calidad y pertinencia de la información. Se consideraron únicamente los árboles nuevos, descartando aquellos con medidas repetidas. Además, se excluyeron los ejemplares que presentaban daños en el tronco, raíces expuestas o dañadas, así como aquellos que tenían datos faltantes en alguna de las variables seleccionadas para el modelo. También se decidió omitir del estudio todas las plantas con fisiología perennifolia, ya que su alta diversidad y variabilidad generaban numerosos valores atípicos que afectaban negativamente los modelos propuestos; esta decisión se tomó tras revisar la distribución de las variables y evaluar los supuestos estadísticos de los modelos.

Para el análisis, se seleccionaron 10 variables de interés (5 cuantitativas y 5 cualitativas) con el objetivo de explicar la relación entre distintas características morfológicas del árbol y su altura total. Tras evaluar el ajuste de las variables en el modelo, se identificó que `altura_tot`, `fisiologia`, `tipo_arbol`, `densidad`, `formatronc`, `diam_ecuat`, `perim_basa` y `diam_polar` ofrecieron el mejor desempeño dentro del modelo lineal generalizado propuesto.

Finalmente, con la información depurada y las variables seleccionadas, se procedió a evaluar los supuestos estadísticos y a construir el modelo lineal generalizado que permitió identificar los principales factores asociados al crecimiento del arbolado urbano en la ciudad.

Exploración y selección de variables

La variable respuesta seleccionada para nuestro análisis es `altura_tot`, la cual representa la altura total del árbol desde la base del tronco hasta su punto más alto, expresada en metros. Esta variable es de tipo cuantitativa, continua y de razón, lo que permite aplicar diversos métodos estadísticos y modelos matemáticos para su análisis. La elección de esta variable se debe a su importancia en la caracterización del crecimiento y desarrollo de los árboles, así como en la evaluación de factores ambientales y estructurales que pueden influir en su variabilidad.

Para identificar las variables que podrían estar relacionadas con la altura total de un árbol (`altura_tot`), es esencial considerar diversos factores que influyen en su crecimiento. Basándonos en la literatura existente, los principales factores son:

1. **diam_ecuat (Diámetro ecuatorial de la copa):** El diámetro de la copa de un árbol suele estar vinculado con su altura, dado que árboles más altos suelen desarrollar copas más amplias. Estudios sobre la alometría arbórea han identificado una relación significativa entre el diámetro del tallo y el diámetro de la copa, lo que sugiere que medir la copa puede proporcionar información indirecta sobre la altura del árbol (Forestalmanderero, s.f.).
2. **perim_basa (Perímetro de la base del tronco):** La medición del perímetro basal del tronco es clave para estimar la edad y el tamaño del árbol. En estudios forestales, se ha encontrado una correlación entre el diámetro del tronco a la altura del pecho (DAP) y la altura del árbol, lo que sugiere que el grosor del tronco puede ser un predictor confiable del crecimiento vertical (FAO, s.f.).
3. **ang_inclin (Ángulo de inclinación del tronco):** La inclinación del tronco puede modificar el patrón de crecimiento de un árbol, ya que los árboles inclinados desarrollan madera de reacción para corregir su postura. Este proceso puede influir en la tasa de crecimiento y en la altura alcanzada por el árbol a lo largo del tiempo (SciELO, 2019).
4. **diam_polar (Diámetro polar de la copa):** El diámetro polar de la copa es otra medida que complementa el diámetro ecuatorial en la evaluación del desarrollo del árbol. Diferentes estudios han resaltado la importancia de la copa en el análisis del crecimiento arbóreo, ya que la extensión del follaje está relacionada con la capacidad del árbol para captar luz y desarrollar mayor altura (Guía de Arbolado, s.f.).
5. **tipo_arbol (Tipo de árbol):** La altura que un árbol puede alcanzar depende en gran medida de su especie y morfología. Por ejemplo, las palmas suelen crecer más en altura que los arbustos, debido a diferencias en su estructura y fisiología. La clasificación del árbol por tipo es un factor fundamental para determinar su crecimiento potencial (Guía de Arbolado, s.f.).

Sin embargo, no todas las variables seleccionadas en este estudio cuentan con respaldo en la literatura existente. Por ello, se llevará a cabo un análisis para identificar posibles

influencias de aquellas que no han sido previamente documentadas en la bibliografía o sí por el contrario alguna de las ya mencionadas no presenta una relación influyente en la variable de estudio seleccionada.

Variables cuantitativas

Para un acercamiento descriptivo se realizó un scatterplot por pares para nuestras variables cuantitativas en la Figura 1.




Figura 1: Gráfico de pares

En el gráfico se observa que las correlaciones más fuertes se encuentran entre las medidas de tamaño: diámetro, perímetro y altura. Esto sugiere que estas características crecen de manera proporcional entre sí. El ángulo de inclinación muestra correlaciones más débiles con las otras variables, indicando que es una característica relativamente independiente del tamaño de la estructura medida.

Se observan algunos valores atípicos, particularmente en las medidas de tamaño, y la dispersión de los datos tiende a aumentar con el tamaño en varias de las relaciones.

Las relaciones entre las variables de tamaño muestran patrones no lineales en algunos casos, lo que sugiere que las proporciones pueden cambiar a medida que la estructura crece. Para identificar que tan fuerte son estas relaciones lineales y no lineales se procede a calcular las medidas de correlación entre las variables en las siguientes tablas.

	diam_ecuat	perim_basa	ang_inclin	diam_polar	altura_tot
diam_ecuat	1.000	0.746	-0.001	0.775	0.799
perim_basa	0.746	1.000	0.041	0.668	0.708
ang_inclin	-0.001	0.041	1.000	0.007	0.011
diam_polar	0.775	0.668	0.007	1.000	0.949
altura_tot	0.799	0.708	0.011	0.949	1.000

Cuadro 1: Correlación de Pearson

- La correlación más alta se observa entre el diámetro polar y la altura total, con un coeficiente de 0.949, indicando una relación positiva muy fuerte. Esto sugiere que cuando el diámetro polar aumenta, la altura total tiende a aumentar de manera muy proporcional.
- El diámetro ecuatorial muestra correlaciones fuertes con varias variables: con altura total (0.799), con diámetro polar (0.775) y con perímetro basal (0.746). Esto indica que esta medida está consistentemente relacionada con las otras dimensiones de tamaño.
- El perímetro basal presenta correlaciones moderadamente fuertes con la altura total (0.708) y el diámetro polar (0.668), además de su ya mencionada correlación con el diámetro ecuatorial.
- El ángulo de inclinación muestra correlaciones muy débiles o prácticamente nulas con todas las variables: -0.001 con diámetro ecuatorial, 0.041 con perímetro basal, 0.007 con diámetro polar y 0.011 con altura total. Esto sugiere que el ángulo de inclinación es independiente de las otras características morfológicas.
- Todas las correlaciones entre las variables de tamaño (diámetros, perímetro y altura) son positivas y significativas, mientras que el ángulo de inclinación se comporta de manera independiente.

	diam_ecuat	perim_basa	ang_inclin	diam_polar	altura_tot
diam_ecuat	1.000	0.580	-0.046	0.597	0.635
perim_basa	0.580	1.000	-0.024	0.479	0.497
ang_inclin	-0.046	-0.024	1.000	-0.007	-0.009
diam_polar	0.597	0.479	-0.007	1.000	0.764
altura_tot	0.635	0.497	-0.009	0.764	1.000

Cuadro 2: Correlación de Kendall

- La correlación más alta se observa entre el diámetro polar y la altura total (0.764), siendo más baja que la correlación de Pearson pero aún indicando una fuerte relación monótona positiva entre estas variables.
- El diámetro ecuatorial muestra correlaciones moderadas con la altura total (0.635), el diámetro polar (0.597) y el perímetro basal (0.580). Estos valores son considerablemente más bajos que los coeficientes de Pearson, sugiriendo una posible influencia por valores extremos.

- El perímetro basal presenta correlaciones moderadas con la altura total (0.497) y el diámetro polar (0.479), además de su correlación con el diámetro ecuatorial ya mencionada. Estas correlaciones son notablemente más bajas que las de Pearson.
- El ángulo de inclinación muestra correlaciones negativas muy débiles con todas las variables: -0.046 con diámetro ecuatorial, -0.024 con perímetro basal, -0.007 con diámetro polar y -0.009 con altura total. Esto confirma, al igual que Pearson, la independencia del ángulo de inclinación respecto a las otras variables.
- En general, las correlaciones de Kendall son más conservadoras que las de Pearson, lo que sugiere que algunas de las relaciones lineales detectadas por Pearson podrían estar sobrestimadas debido a valores atípicos o relaciones no lineales en los datos.

	diam_ecuat	perim_basa	ang_inclin	diam_polar	altura_tot
diam_ecuat	1.000	0.768	-0.066	0.789	0.829
perim_basa	0.768	1.000	-0.035	0.667	0.683
ang_inclin	-0.066	-0.035	1.000	-0.012	-0.015
diam_polar	0.789	0.667	-0.012	1.000	0.923
altura_tot	0.829	0.683	-0.015	0.923	1.000

Cuadro 3: Correlación de Spearman

- La correlación más alta se observa entre el diámetro polar y la altura total con un coeficiente de 0.923, lo que indica una relación monótona positiva muy fuerte. Esto sugiere que a medida que aumenta el diámetro polar, la altura total tiende a aumentar de manera muy consistente.
- El diámetro ecuatorial también muestra correlaciones fuertes, presentando coeficientes de 0.829 con la altura total, 0.789 con el diámetro polar y 0.768 con el perímetro basal. Estas correlaciones sustanciales indican que el diámetro ecuatorial mantiene una relación moderada con las otras variables.
- Por su parte, el perímetro basal exhibe correlaciones moderadamente fuertes con las otras variables, aunque con coeficientes ligeramente menos intensos: 0.768 con el diámetro ecuatorial, 0.683 con la altura total y 0.667 con el diámetro polar. Esto sugiere que, si bien el perímetro basal está relacionado con las otras dimensiones, su variación no es tan fuerte como en los casos anteriores.
- Como se evidencio en el cálculo de los coeficientes anteriores se mantiene la tendencia negativa del ángulo de inclinación respecto a todas las demás variables, con coeficientes que van desde -0.066 hasta -0.012. Estos valores cercanos a cero confirman que el ángulo de inclinación es esencialmente independiente de las otras características morfológicas estudiadas.

	diam_ecuat	perim_basa	ang_inclin	diam_polar	altura_tot
diam_ecuat	1.000	0.409	0.010	0.425	0.471
perim_basa	0.409	1.000	-0.015	0.262	0.270
ang_inclin	0.010	-0.015	1.000	0.037	0.029
diam_polar	0.425	0.262	0.037	1.000	0.667
altura_tot	0.471	0.270	0.029	0.667	1.000

Cuadro 4: Correlación Xi

- La correlación más fuerte se observa entre el diámetro polar y la altura total, con un coeficiente de 0.667, lo que indica una relación moderadamente fuerte. Este resultado sugiere que existe una dependencia funcional significativa entre estas dos variables.
- El diámetro ecuatorial muestra correlaciones moderadas con varias variables: 0.471 con la altura total, 0.425 con el diámetro polar y 0.409 con el perímetro basal. Estas correlaciones, aunque más débiles que las observadas con otros coeficientes, sugieren la existencia de relaciones no lineales entre estas variables morfológicas.
- El perímetro basal presenta correlaciones relativamente débiles con la mayoría de las variables, mostrando coeficientes de 0.270 con la altura total y 0.262 con el diámetro polar. Estos valores más bajos sugieren que las relaciones del perímetro basal con otras variables podrían ser más complejas o menos directas de lo que indicaban los análisis previos.
- El ángulo de inclinación mantiene su patrón de independencia respecto a las demás variables, con correlaciones Xi extremadamente bajas que van desde -0.015 hasta 0.037.
- La comparación de estos resultados con los coeficientes de Pearson, Kendall y Spearman previamente calculados revela que las relaciones entre las variables podrían ser más complejas de lo inicialmente supuesto. Los valores generalmente más bajos del coeficiente Xi sugieren que, aunque existen relaciones entre las variables, estas podrían no seguir patrones simples y podrían requerir modelos más sofisticados para su completa caracterización.

	diam_ecuat	perim_basa	ang_inclin	diam_polar	altura_tot
diam_ecuat	1.000	0.429	-0.039	0.106	0.199
perim_basa	0.429	1.000	0.058	-0.061	0.194
ang_inclin	-0.039	0.058	1.000	-0.007	0.007
diam_polar	0.106	-0.061	-0.007	1.000	0.862
altura_tot	0.199	0.194	0.007	0.862	1.000

Cuadro 5: Correlación parcial de Pearson

En conclusión, el análisis de correlaciones parciales revela que muchas de las relaciones fuertes observadas en las correlaciones simples se debían en realidad a la influencia de otras variables. La única relación que mantiene una fuerza similar es la existente entre el diámetro

polar y la altura total, sugiriendo que esta es una relación verdaderamente fundamental en la estructura morfológica estudiada.

Para determinar la pertinencia de las transformaciones funcionales, se analizó el comportamiento de los datos bajo diferentes funciones matemáticas, incluyendo logarítmica, exponencial y raíz cuadrada, entre otras. La selección de la transformación más apropiada se basó en su capacidad para optimizar la relación entre las variables explicativas. Se elaboraron gráficos de dispersión comparativos, antes y después de aplicar las transformaciones, para evaluar visualmente la efectividad de estos ajustes en la estructura de los datos.

Las Figuras 2, 3 y 4 muestran la comparación entre la distribución del diámetro ecuatorial, el perímetro basal y el diámetro polar en su escala original y después una transformación logarítmica. En la parte superior, el histograma del original muestra una marcada asimetría positiva con una alta concentración de valores bajos y una larga cola hacia la derecha, mientras que su Q-Q plot correspondiente revela una clara desviación de la normalidad especialmente en los valores altos. En contraste, la transformación logarítmica (gráficos inferiores) resulta en una distribución más simétrica y cercana a la normal, como se evidencia en el histograma más equilibrado y en el Q-Q plot que muestra puntos más alineados con la línea de referencia, indicando que la transformación logarítmica mejora significativamente la normalidad de los datos.




Figura 2: Transformación lineal para `diam_ecuat`




Figura 3: Transformación lineal para `perim_basa`




Figura 4: Transformación lineal para `diam_polar`

En la Figura 5, se compara la distribución original de la variable altura total con su versión transformada logarítmicamente. En la parte superior, el histograma muestra una distribución fuertemente sesgada a la derecha, mientras que el Q-Q plot revela una clara desviación de la normalidad, especialmente en los valores más altos. En contraste, tras aplicar

la transformación logarítmica (gráficos inferiores), la distribución se vuelve un poco más simétrica, y cercana a la normal. Esto se refleja en un histograma más equilibrado y en un Q-Q plot con puntos mejor alineados con la línea de referencia. Aunque persisten ligeras desviaciones, la transformación logarítmica mejora significativamente la normalidad de los datos.




Figura 5: Transformación lineal para `altura_tot`

Dado que el ángulo de inclinación (`ang_inclin`) muestra correlaciones muy bajas con todas las variables, no requeriría transformación. Es por este motivo, que se decide eliminar esta característica como posible variable explicativa.

Variables cualitativas

Para tener un primer acercamiento a la relación entre nuestras variables categóricas y la altura total del árbol, se realizarán boxplots por cada variable cualitativa.




Figura 6: Bloxplot Fisiología vs Altura Total

Se observa que los árboles perennifolios presentan una mediana de altura ligeramente superior a la de los semicaducifolios, mientras que los caducifolios tienen la menor altura promedio. En los grupos perennifolio y semicaducifolio se detectan varios valores atípicos, con ejemplares que superan los 15-20 metros de altura. La dispersión de los datos es más pronunciada en los árboles semicaducifolios, como lo muestra el tamaño de la caja en el gráfico, mientras que los caducifolios exhiben la menor variabilidad en altura. Este patrón sugiere que la fisiología del árbol, es decir, el comportamiento de la caída de hojas entre estaciones, influye de manera significativa en la altura total.

Sin embargo, la presencia de numerosos outliers, especialmente en el grupo de los perennifolios (aquellos que no pierden sus hojas), indica que existen otros factores que también pueden incidir en el crecimiento vertical de estas especies.




Figura 7: Bloxplot Tipo de árbol vs Altura Total

En este gráfico, los árboles muestran la mayor altura mediana y también la mayor variabilidad en su distribución, con numerosos valores atípicos que superan los 15 metros de altura. En contraste, los arbustos y palmas presentan alturas medianas considerablemente menores y una distribución más compacta, lo que indica menor variabilidad en sus alturas. Las palmas muestran algunos valores atípicos que alcanzan cerca de los 8 metros, pero estos son menos extremos que los observados en la categoría de árboles.




Figura 8: Bloxplot Densidad vs Altura Total

Se observa que, a medida que aumenta la densidad, la mediana de la altura total tiende a incrementarse, también se nota una mayor dispersión en los grupos de mayor densidad, con un rango intercuartílico más amplio y un número considerable de valores atípicos. En particular, los grupos de 51-75 % y 76-100 % muestran una mayor variabilidad en comparación con los grupos de menor densidad, lo que indica que en áreas más densas hay una mayor heterogeneidad en la altura total.




Figura 9: Bloxplot Transparencia vs Altura Total

Se observa una tendencia decreciente en la mediana de la altura total a medida que aumenta la transparencia, lo que sugiere una posible relación negativa entre ambas variables. Además, los grupos con menor transparencia (0-25 % y 26-50 %) presentan una mayor dispersión y un mayor número de valores atípicos en comparación con los grupos de mayor transparencia (51-75 % y 76-100 %), que muestran distribuciones más compactas. Esto indica que en condiciones de mayor transparencia, la altura total es más homogénea y tiende a ser menor.




Figura 10: Bloxplot Forma del tronco vs Altura Total

La clase *Fuste único* presenta la mayor mediana de altura total, con una amplia dispersión y numerosos valores atípicos, lo que indica una mayor variabilidad en la altura de los árboles dentro de esta categoría. En contraste, las demás clases muestran alturas más homogéneas. Se observan valores atípicos en todas las categorías, evidenciando variabilidad dentro de cada grupo. Un aspecto interesante es que, aunque originalmente esta variable tenía seis categorías, la clase *Tronco Espiralado* no aparece en la muestra de 500 observaciones, probablemente debido a la semilla utilizada o a que esta categoría tenía muy pocas observaciones en la base de datos original.




Figura 11: Bloxplot variables categóricas vs Altura Total, eliminando los perennifolios

Dado que se observa una inusual cantidad de outliers en la categoría Perennifolio de la variable **fisiología** se evalúa al excluirla de la base de datos y se observa una reducción notable en la cantidad de datos atípicos presentes en las demás variables categóricas analizadas. Los valores extremos, que antes se concentraban principalmente en el grupo de los perennifolios, disminuyen significativamente tras su eliminación.

Finalmente, se procede a calcular la matriz de coeficientes de Cramér, esto para medir la asociación entre las variables categóricas dentro del conjunto de datos.

	fisiologia	tipo_arbol	densidad	transparen	formatronc
fisiologia	1.00000000	0.17996349	0.09563459	0.08997817	NaN
tipo_arbol	0.17996349	1.00000000	0.07614031	0.08584317	NaN
densidad	0.09563459	0.07614031	1.00000000	0.94448954	NaN
transparen	0.08997817	0.08584317	0.94448954	1.00000000	NaN
formatronc	NaN	NaN	NaN	NaN	1

Cuadro 6: Matriz de coeficientes de Cramer

Podemos ver que, el valor 0.9445 indica una asociación muy alta entre la variable *transparen* y *densidad*, lo que nos lleva a pensar que miden características similares, lo que puede llevar a redundancia en el modelo de regresión. Por esto se procede a hacer un ANOVA para cada una de estas dos variables e identificar con cual nos deberíamos quedar, es decir cual tiene mas relación con la variable que pretendemos explicar. Ahora bien, midiendo el porcentaje de la variabilidad en la variable dependiente, tenemos un valor de 0.0167 para *densidad* y 0.0190 para *transparen*, donde la ultima tiene un poco más de asociación con la altura de los árboles, por lo tanto nos quedamos con *transparen*.

Fase de estimación

Después de realizar diversas pruebas para identificar un modelo que mejor se ajustara a los supuestos de la regresión lineal, el modelo final que proponemos tiene la siguiente forma,

$$\begin{cases} Y_k \sim \text{Gamma}(\mu_i, \phi) \\ \mu_k = \log(\beta_0 + \beta_1 \log(x_{k1}) + \beta_2 \log(x_{k2}) + \beta_3 \log(x_{k3}) \\ \quad + \beta_4 x_{k4} + \beta_5 x_{k5} + \beta_6 x_{k6} + \beta_7 x_{k7} + \beta_8 x_{k8} + \beta_9 x_{k9} + \beta_{10} x_{k10} \\ \quad + \beta_{11} x_{k11} + \beta_{12} x_{k12} + \beta_{13} x_{k13} + \beta_{14} x_{k14} + \beta_{15} x_{k15} + \beta_{16} x_{k16} + \beta_{17} x_{k17}) \\ Y_1, Y_2, \dots, Y_n \text{ independientes.} \end{cases}$$

donde,

$$Y_k : \text{Altura total del árbol } (\log(\text{altura_tot}))$$

y las variables explicativas cuantitativas se derivan de:

x_{k1} = diam_ecuat : Diámetro ecuatorial de la copa

x_{k2} = perim_basa : Perímetro basal del tronco

x_{k3} = diam_polar : Diámetro polar de la copa

Note que realizamos una transformación logarítmica a estas últimas tres; esto porque permite estabilizar la varianza del modelo y a su vez mantener su interpretabilidad.

Luego, las x variables explicativas cualitativas transformadas en dummies quedarían de la siguiente manera:

Para la variable *Fisiología*, tomamos como categoría de referencia *Caducifolio* y tenemos lo siguiente

$$x_{k4} = \begin{cases} 1 & \text{si el árbol es caducifolio} \\ 0 & \text{en otro caso} \end{cases}$$

$$x_{k5} = \begin{cases} 1 & \text{si el árbol es semicaducifolio} \\ 0 & \text{en otro caso} \end{cases}$$

Para la variable *tipo_arbol*, tomamos como categoría de referencia *Árbol* y tenemos lo siguiente

$$x_{k6} = \begin{cases} 1 & \text{si la planta es un arbusto} \\ 0 & \text{en otro caso} \end{cases}$$

$$x_{k7} = \begin{cases} 1 & \text{si la planta es un arbol} \\ 0 & \text{en otro caso} \end{cases}$$

Para la variable *densidad*, tomamos como categoría de referencia *0-25 %* y tenemos lo siguiente

$$x_{k8} = \begin{cases} 1 & \text{si la densidad es entre 0 \% y 25 \%} \\ 0 & \text{en otro caso} \end{cases}$$

$$x_{k9} = \begin{cases} 1 & \text{si la la densidad es entre 25 \% y 50 \%} \\ 0 & \text{en otro caso} \end{cases}$$

$$x_{k10} = \begin{cases} 1 & \text{si la la densidad es entre 50 \% y 75 \%} \\ 0 & \text{en otro caso} \end{cases}$$

$$x_{k11} = \begin{cases} 1 & \text{si la la densidad es entre 75 \% y 100 \%} \\ 0 & \text{en otro caso} \end{cases}$$

y para la variable *formatronc*, tomamos como categoría de referencia *Bifurcado* y tenemos lo siguiente

$$x_{k13} = \begin{cases} 1 & \text{si el tronco es de fuste único} \\ 0 & \text{en otro caso} \end{cases}$$

$$x_{k14} = \begin{cases} 1 & \text{si el tronco tiene mas de 10 ramificaciones} \\ 0 & \text{en otro caso} \end{cases}$$

$$x_{k15} = \begin{cases} 1 & \text{si el tronco tiene menos de 10 ramificaciones} \\ 0 & \text{en otro caso} \end{cases}$$

$$x_{k16} = \begin{cases} 1 & \text{si el tronco es espiralado} \\ 0 & \text{en otro caso} \end{cases}$$

$$x_{k17} = \begin{cases} 1 & \text{si el tronco es retorcido} \\ 0 & \text{en otro caso} \end{cases}$$

Cabe a notar que hemos removido la variable transparencia, esto porque presentaba colinealidad con la variable densidad. También hemos removido los árboles de tipo "Perennifolio" porque no permitía que el modelo tuviera el supuesto de varianza constante entre grupos de variables.

Ahora, haciendo la estimación de los parámetros,

Parámetro	Estimación	Error Estándar	Valor t	p - valor
(Intercept)	1.12225	0.05476	20.495	$< 2 \times 10^{-16}$
fisiologiaSemicaducifolio	0.07363	0.02132	3.454	0.000646
tipo_arbolArbusto	-0.03214	0.03155	-1.018	0.309419
densidad26-50 %	-0.13904	0.03750	-3.708	0.000256
densidad51-75 %	-0.09619	0.03445	-2.792	0.005630
densidad76-100 %	-0.18092	0.03397	-5.327	$2,18 \times 10^{-7}$
formatroncFuste unico	0.10133	0.02263	4.478	$1,13 \times 10^{-5}$
formatroncNumero de ramificaciones > 10	-0.17791	0.07009	-2.538	0.011726
formatroncNumero de ramificaciones < 10	-0.12471	0.02716	-4.591	$6,89 \times 10^{-6}$
formatroncTronco retorso	-0.05634	0.08655	-0.651	0.515680
log(diam_ecuat + 0.01)	0.07395	0.02484	2.978	0.003182
log(perim_basa + 0.01)	0.24583	0.02205	11.149	$< 2 \times 10^{-16}$
log(diam_polar + 0.01)	0.50819	0.02340	21.714	$< 2 \times 10^{-16}$

Cuadro 7: Estimación de parámetros del modelo Gamma

Parámetro de Dispersion para la Familia Gamma: 0.02106112

Devianza Nula: 103.9776 on 270 degrees of freedom

Devianza Residual: 5.3737 on 258 degrees of freedom

AIC: 447

Iteraciones de Fisher Scoring: 5

Interpretando los parámetros de localización tenemos que,

Interpretación de los coeficientes del modelo Gamma con enlace log

- $\hat{\beta}_1 = 0,07395$: Por cada incremento del 1 % en el *diámetro ecuatorial* (*diam_ecuat*), el logaritmo de la altura total esperada del árbol aumenta en 0.07395, manteniendo constantes las demás variables. En términos porcentuales, la altura esperada aumenta aproximadamente un $e^{0,07395} - 1 \approx 7,7\%$.

- $\hat{\beta}_2 = 0,24583$: Por cada incremento del 1 % en el *perímetro basal del tronco* (*perim_basa*), el logaritmo de la altura total esperada del árbol aumenta en 0.24583. Esto equivale a un aumento aproximado del $e^{0,24583} - 1 \approx 27,8 \%$ en la altura esperada.
- $\hat{\beta}_3 = 0,50819$: Por cada incremento del 1 % en el *diámetro polar de la copa* (*diam_polar*), el logaritmo de la altura esperada del árbol aumenta en 0.50819, es decir, un incremento de aproximadamente $e^{0,50819} - 1 \approx 66,2 \%$ en la altura esperada, siendo el predictor de mayor impacto entre las variables continuas.
- $\hat{\beta}_5 = 0,07363$: Los árboles *semicaducifolios* presentan en promedio un aumento del $e^{0,07363} - 1 \approx 7,6 \%$ en su altura esperada respecto a los *caducifolios* (categoría de referencia).
- $\hat{\beta}_6 = -0,03214$: Las plantas clasificadas como *arbustos* son en promedio un $e^{-0,03214} - 1 \approx -3,2 \%$ más bajas que los *árboles*, aunque esta diferencia no es estadísticamente significativa ($p = 0,309$).
- $\hat{\beta}_9 = -0,13904$: Los árboles ubicados en zonas con densidad de cobertura del 26–50 % son aproximadamente un $e^{-0,13904} - 1 \approx -13,0 \%$ más bajos que aquellos en la categoría de referencia (0–25 %).
- $\hat{\beta}_{10} = -0,09619$: Los árboles en áreas con densidad de 51–75 % presentan alturas esperadas un $e^{-0,09619} - 1 \approx -9,2 \%$ menores respecto al grupo de referencia (0–25 %).
- $\hat{\beta}_{11} = -0,18092$: Los árboles en zonas con densidad de 76–100 % tienen alturas esperadas un $e^{-0,18092} - 1 \approx -16,6 \%$ más bajas que aquellos con densidad de 0–25 %, siendo un efecto altamente significativo ($p < 0,001$).
- $\hat{\beta}_{13} = 0,10133$: Los árboles con tronco de *fuste único* son en promedio un $e^{0,10133} - 1 \approx 10,7 \%$ más altos que los *bifurcados* (referencia).
- $\hat{\beta}_{14} = -0,17791$: Los árboles con más de 10 ramificaciones presentan una altura esperada un $e^{-0,17791} - 1 \approx -16,3 \%$ menor respecto a los bifurcados.
- $\hat{\beta}_{15} = -0,12471$: Los árboles con menos de 10 ramificaciones son aproximadamente un $e^{-0,12471} - 1 \approx -11,8 \%$ más bajos que los bifurcados, con un efecto altamente significativo ($p < 0,001$).
- $\hat{\beta}_{17} = -0,05634$: Los árboles con tronco *retorcido* son un $e^{-0,05634} - 1 \approx -5,5 \%$ más bajos que los bifurcados, aunque este efecto no resulta estadísticamente significativo ($p = 0,516$).

Interpretando el parámetro de escala que es el error estándar residual, podemos decir que en promedio, las predicciones del modelo se desvían aproximadamente 0.1262 unidades logarítmicas de los valores observados. En términos de altura, esto equivale a una desviación de aproximadamente 1.13 metros.

Anexo: Evaluación de Supuestos

Se realiza la revisión de supuestos:

Distribución de Variable Respuesta

Realizándole este test se tiene que:

Cuadro 8: Distribución Predecida de Respuesta

Distribución	Probabilidad (%)
Chi	34
Tweedie	28
Pareto	9

Y como la distribución χ^2 es un caso particular de la distribución Gamma, podemos decir que identificamos bien la distribución de nuestra variable dependiente.

Distribución de Residuos

Queremos evaluar la distribución de los residuos:




Figura 12: QQ-plot uniforme (instrucción check_model).

Donde vemos que los residuos si tienden a alinearse con la linea, pero en las colas tienden a alejarse. Por lo que, la distribución de los residuos uniformes pueden ser una buena opción.

Cuadro 9: Distribución Predecida de los Residuales

Distribución	Probabilidad (%)
Normal	50
Cauchy	19
Beta	12

Note que, en este test nos arroja residuos normales. Ante la duda, decidimos realizar dos pruebas de Shapiro-Wilk para dos distribuciones (Normal y uniforme). Se obtuvieron los siguientes resultados:

Cuadro 10: Resultados de la prueba de normalidad de Shapiro-Wilk para los residuos

Prueba de normalidad	Estadístico W	Valor p
Shapiro-Wilk	0.85319	$< 2,2 \times 10^{-16}$

Cuadro 11: Resultados de la prueba de uniformidad de Shapiro-Wilk para los residuos

Prueba de uniformidad	Estadístico W	Valor p
Shapiro-Wilk	0.036239	0.5704

como se rechaza la hipótesis de normalidad, y no la de uniformidad, decimos que los residuos se distribuyen uniformemente.

Independencia de Residuos

Se espera que los residuos no muestren patrón alguno a la hora de graficarlos de manera ordenada, como se muestra en el siguiente gráfico:




Figura 13: Gráfico de residuos Ordenados.

En el que no se observa tendencia alguna. Al realizársele un test de Durbin-Watson, se obtuvo:

Como No se rechaza la hipótesis nula, decimos que hay independencia entre residuos.

Cuadro 12: Resultados de la prueba de independencia de Durbin-Watson

Prueba de independencia	DW	Valor p
Durbin-Watson	1.9438	0.2743

Estructura Sistemática

Si en el gráfico de residuos versus predicciones no se encuentra algún patrón o agrupamiento de puntos, se puede asumir que el modelo está bien especificado (bajo enlace y predictores):




Figura 14: Gráfico de Residuos vs. Predicciones.

Se puede ver que no existe alguna tendencia entre ambos, así la línea suavizada no sea exactamente una línea recta de pendiente 0.

Homogeneidad de Varianzas

Revisando con el gráfico:




Figura 15: Gráfico de Homogeneidad de Varianzas(instrucción check_model).

Se puede observar un problema del modelo respecto a la varianza, la cual no es homogénea para todos los valores estimados. Este gráfico en particular es el motivo por el que decidimos agregar escala log a las variables cuantitativas; modelos sin estos ajustes daban varianza mucho menos homogénea. En caso de querer corregir este problema, ya tendríamos que explicar la varianza con alguna variable exógena.

Colinealidad

El siguiente gráfico nos permite revisar rápidamente la colinealidad (bajo criterio VIF) de las variables exógenas:




Figura 16: Gráfico de Colinealidad (instrucción check_model).

Al tenerse que ninguna tiene un VIF mayor a 10, se concluye que no hay multicolinealidad extrema. Para valores exactos, tenemos la siguiente tabla:

Cuadro 13: Diagnóstico de multicolinealidad para el modelo Gamma con enlace logarítmico

Término	VIF	IC 95 % (VIF)	VIF ajustado
Fisiología	1.13	[1.04, 1.39]	1.06
Tipo_árbol	1.22	[1.11, 1.46]	1.11
Densidad	1.30	[1.16, 1.54]	1.04
Forma del tronco	1.22	[1.11, 1.46]	1.03
log(diam_ecuat + 0,01)	4.69	[3.86, 5.76]	2.17
log(perim_basa + 0,01)	4.00	[3.31, 4.90]	2.00
log(diam_polar + 0,01)	3.52	[2.92, 4.30]	1.88

Datos Influyentes y de Palanca

Revisamos el gráfico de la distancia de Cook:




Figura 17: Distancia de Cook.

Acá se notan estas varias observaciones mostrándose como influyentes (particularmente las 12,23, y 158). Ahora, revisando un gráfico de palanca, podemos ver que existen en efecto datos de palanca:




Figura 18: Graficación de Datos Leverage.

Esto también puede arruinar las estimaciones de los modelos. Como se sospechaba también de datos influyentes, decidimos realizar una comparación entre este modelo y un modelo robusto (mediante el comando `robglm` de la librería `robustbase`). Nos queda la siguiente tabla:

Cuadro 14: Comparación de coeficientes entre el modelo Gamma clásico y el modelo robusto (`glmrob`)

Parámetro	GLM	GLM robusto (removiendo datos)
Intercepto	1.122	1.091
fisiología semidecidua	0.074	0.072
tipo arbusto	-0.032	-0.032
densidad 26–50 %	-0.139	-0.122
densidad 51–75 %	-0.096	-0.109
densidad 76–100 %	-0.181	-0.180
fuste único	0.101	0.098
ramificaciones > 10	-0.178	-0.188
ramificaciones < 10	-0.125	-0.133
tronco retorcido	-0.056	-0.044
$\log(\text{diam_ecuat} + 0,01)$	0.074	0.104
$\log(\text{perim_basa} + 0,01)$	0.246	0.221
$\log(\text{diam_polar} + 0,01)$	0.508	0.494

Donde se puede ver que las estimaciones no cambian tanto entre modelos, por lo que se concluye que influyentes y leverage no distorsionaron significativamente el ajuste global. Una forma de verificar el movimiento anterior, es con el siguiente gráfico:




Figura 19: Graficación de Datos Leverage del commando check_model.

Con el que se puede concluir, bajo el criterio de que se mantengan los datos dentro del intervalo, que es correcto mantener el modelo original.

Bondad de Ajuste

Utilizando el gráfico “.envelope”, el cual realiza simulaciones de montecarlo con el modelo ajustado y brinda bandas de confianza bajo ese modelo, se puede ver que, removiendo datos atípicos, el modelo ajusta correctamente:




Figura 20: Gráfico de Bandas calculadas mediante simulación de Montecarlo.

Referencias

- Forestalmaderero. (s.f.). *Definir la alometría del diámetro del tallo y la copa de los árboles urbanos*. Recuperado de <https://www.forestalmaderero.com>
- FAO. (s.f.). *Medición de árboles y su relación con el crecimiento forestal*. Recuperado de <https://www.fao.org>

- Scielo. (2019). *Formación de madera de reacción en árboles inclinados*. Recuperado de <https://www.scielo.org.mx>
- Guía de Arbolado. (s.f.). *Factores que influyen en el crecimiento de los árboles*. Recuperado de <https://www.guiadearbolado.com.ar>